

Prediksi Customer Churn — Telco

Perbandingan tiga model dan aplikasi Streamlit terkalibrasi

KELOMPOK 12 / KELAS B2

Muhamad Akhdan Ramadhan — J0404241102

Thevan Erlangga — J0404241073

Fachri Abyasa Tarid — J0404241136

Mata Kuliah Pembelajaran Mesin • Project Akhir 2026

Latar belakang & rumusan masalah

Churn = pelanggan berhenti berlangganan

- Pelanggan memiliki profil kontrak, layanan, dan pembayaran yang berbeda.
- Identifikasi risiko membantu menentukan prioritas tindak lanjut retensi [1, 4].
- Masalah: bagaimana memprediksi churn dari data pelanggan secara terukur?
- Tantangan: kelas churn minoritas dan biaya false alarm / churn terlewat berbeda.
- Prediksi risiko belum membuktikan efektivitas tindakan retensi.

Tujuan project

Klasifikasi supervised tabular, bukan forecasting

- Memahami dataset melalui EDA dan preprocessing yang sesuai.
- Membandingkan Logistic Regression, Decision Tree, dan Random Forest.
- Memilih model inti melalui validation CV-F1 pada data training.
- Menghasilkan probabilitas terkalibrasi dan keputusan dengan threshold train-only.
- Menyediakan aplikasi single/batch CSV dengan validasi dan dashboard transparan.

Studi literatur — metode & evaluasi

Lima jurnal terverifikasi • ringkasan hasil penulis, bukan hasil project

Referensi	Dataset	Metode	Hasil utama
[1] Sana et al. (2022)	4 dataset; termasuk Telco 7.043	8 model; transformasi + feature selection + grid search	WOE+LR: AUC 0,796 / F1 0,79 (Dataset-1)
[2] Y., Ly & Son (2022)	Orange 3.333	Kernel SVM + SFS/SBS + SMOTE-ENN	Accuracy 0,9888 / F1 0,9901
[3] Bilal et al. (2022)	GitHub 5.000 / BigML 3.333	Clustering + classifier ensemble	Accuracy 94,7% / 92,43%

Project: 3 model tabular + pipeline train-only + sigmoid calibration + Streamlit. Skor jurnal tidak dibandingkan langsung karena dataset dan protokol berbeda.

Studi literatur — early warning & pengembangan

Lima jurnal terverifikasi • ringkasan hasil penulis, bukan hasil project

Referensi	Dataset	Metode	Hasil utama
[4] Zhou et al. (2023)	Operator 900.000 mentah	RF-AdaBoost + SMOTE	P=0,99 / R=0,93 / F1=0,96 (churn)
[5] Khattak et al. (2023)	Telco; 7.033 menurut artikel	BiLSTM-CNN	Accuracy 81% / F-score 65%

Project: 3 model tabular + pipeline train-only + sigmoid calibration + Streamlit. Skor jurnal tidak dibandingkan langsung karena dataset dan protokol berbeda.

Dataset & target

Sumber: IBM Telco Customer Churn di Kaggle — blastchar

Komponen	Jumlah / karakteristik
Data mentah	7.043 pelanggan • 21 kolom (ID + 19 kandidat fitur + target)
Cohort pemodelan	7.032 pelanggan • 18 input fitur + target
Target	Churn Yes=1 / No=0 • 1.869 churn dan 5.163 tidak churn
Numerik	tenure (bulan), MonthlyCharges (\$); SeniorCitizen indikator 0/1
Kategorikal	15 fitur: kontrak, layanan, pembayaran, demografi

Sumber dan arti seluruh 21 variabel ada pada laporan EDA di folder docs.


Pemeriksaan kualitas data

Missing, duplikat, outlier, dan keputusan cleaning

- 11 TotalCharges kosong → numeric coercion → missing; seluruhnya tenure 0 / tidak churn.
- Tidak ada customerID ganda atau baris mentah identik.
- 27 profil duplikat setelah ID/TotalCharges dihapus (termasuk target); tidak dibuang otomatis.
- IQR $1,5\times$ pada tenure, MonthlyCharges, TotalCharges: 0 outlier; tidak dilakukan clipping.
- 18 profil test cocok dengan profil train; menjadi keterbatasan generalisasi profil baru.

EDA — distribusi kelas


Hubungan fitur-target dianalisis pada training set saja



Setelah data dibersihkan, sekitar 73,4% pelanggan tidak churn dan 26,6% churn. Jumlah kedua kelompok tidak seimbang. Karena itu, akurasi perlu dilihat bersama precision, recall, dan F1 agar kemampuan mendeteksi churn tidak terlewat.

EDA — distribusi numerik


Hubungan fitur-target dianalisis pada training set saja



Tenure menunjukkan lama berlangganan, dari pelanggan baru hingga 72 bulan. Tagihan bulanan tersebar dalam beberapa kelompok, sedangkan total tagihan banyak berada pada nilai rendah. StandardScaler menyamakan skala fitur angka untuk Logistic Regression, bukan membuat distribusinya menjadi normal.

EDA — profil churn vs tidak churn


Hubungan fitur-target dianalisis pada training set saja



Pada data training, median lama berlangganan pelanggan churn adalah 10 bulan, sedangkan pelanggan tidak churn 38 bulan. Median tagihannya masing-masing \$79.90 dan \$64.68. Pola ini belum membuktikan sebab-akibat. Titik outlier pada boxplot dihitung per kelompok, berbeda dari tabel IQR yang memeriksa seluruh data sekaligus.

EDA — kontrak, internet, pembayaran


Hubungan fitur-target dianalisis pada training set saja



Pada data training, 43.1% pelanggan kontrak bulanan churn, dibanding 2.9% pada kontrak dua tahun. Persentase churn juga berbeda menurut layanan internet dan cara pembayaran. Ini membantu mengenali pola pelanggan, tetapi belum membuktikan bahwa mengganti kontrak atau metode pembayaran akan mencegah churn.

EDA — korelasi & pilihan fitur

Korelasi bukan identitas dan bukan sebab-akibat



- TotalCharges berkorelasi kuat dengan tenure.
- TotalCharges dihapus agar input aplikasi sederhana.
- Tidak selalu $\text{MonthlyCharges} \times \text{tenure}$.
- Belum ada ablation untuk membuktikan keuntungan penghapusan fitur.

Preprocessing & pencegahan leakage

Fit preprocessing hanya pada training fold

- customerID dihapus; TotalCharges tidak digunakan; 11 catatan tidak lengkap dieksklusi.
- StandardScaler: SeniorCitizen, tenure, MonthlyCharges; OneHotEncoder: 15 kategori.
- Scaling membantu LR; pohon tetap memakai pipeline konsisten walau tidak memerlukannya.
- Class weight dituning untuk imbalance; tanpa SMOTE pada eksperimen project.
- ColumnTransformer + classifier dalam Pipeline; test tidak dipakai untuk fit/tuning.

Tiga algoritma & alasan pemilihan

Membandingkan model linear, pohon tunggal, dan ensemble

Model	Alasan	Risiko / kontrol
Logistic Regression	Ringan; baseline linear log-odds; koefisien mudah dibahas	C dan class_weight dituning
Decision Tree	Aturan non-linear dan interaksi fitur	max_depth / min_samples_split / class_weight
Random Forest	Bagging banyak pohon; pembandingan kompleksitas	Kedalaman dan split dituning; periksa overfitting

Dasar literatur: [1] membandingkan ketiganya; [3]–[4] membahas ensemble churn.

Training, validation & parameter terbaik

80:20 stratified • random_state=42 • CV 5-fold • GridSearch scoring F1

Model	Parameter terbaik	CV-F1
Logistic Regression	C=10; class_weight=balanced; max_iter=1.000	0,6304
Decision Tree	max_depth=5; min_samples_split=2; balanced	0,6147
Random Forest	200 pohon; depth=12; min_samples_split=5; balanced_subsample	0,6260

Train 5.625; test 1.407. Grid: LR 6, DT 12, RF 8 konfigurasi × 5 fold = 130 fit CV, ditambah refit pemenang setiap model. Test tidak masuk fold training.

Evaluasi & perbandingan model inti


Label positif: churn • threshold 0,50 • holdout yang sama

Model	CV-F1	Accuracy	Precision	Recall	F1	AUC
LogisticRegression	0.6304	0.7264	0.4908	0.7861	0.6043	0.8321
RandomForest	0.6260	0.7697	0.5548	0.6765	0.6096	0.8235
DecisionTree	0.6147	0.7363	0.5025	0.7968	0.6163	0.8305

LR dipilih dengan CV-F1 tertinggi pada train. DT memiliki recall/F1 test tertinggi; RF accuracy tertinggi. DT CV-F1 terendah; LR F1 test terendah di antara model inti. Selisih CV-F1 LR–RF hanya 0,0044, bukan bukti unggul mutlak.

Analisis model & overfitting


Gunakan train-validation-test, bukan accuracy saja



- RF: F1 train 0,8217 vs test 0,6096 → indikasi overfitting.
- LR: train 0,6338 vs test 0,6043; gap lebih kecil.
- Baseline selalu tidak churn: accuracy 73,42%, recall churn 0.
- Kompleksitas, regularisasi, class_weight dan interaksi dapat memengaruhi hasil.

Kalibrasi & pemilihan threshold

Model aplikasi: LR + sigmoid calibration 5-fold, train-only



- Grid threshold 0,10–0,60; langkah 0,01.
- F1 maksimum prediksi OOF train → threshold 0,32.
- Kalibrasi di dalam setiap outer training fold.
- OOF F1 0,6338 adalah skor tuning, bukan estimasi independen.
- CHURN jika probabilitas $\geq 32\%$; TETAP jika lebih rendah.

Hyperparameter inti telah dipilih pada train-CV. Test hanya dipakai untuk evaluasi akhir.

Evaluasi konfigurasi aplikasi


Probabilitas dan keputusan berasal dari model yang sama

Konfigurasi	Accuracy	Precision	Recall	F1	AUC	Brier
Threshold 0,32	0.7569	0.5309	0.7353	0.6166	0.8324	0.1414
Threshold 0,50	0.8024	0.6472	0.5642	0.6029	0.8324	0.1414

Threshold 0,32 mendeteksi 275 churn vs 211 pada 0,50; false alarm naik 115 → 243. Trade-off precision–recall; ROC-AUC/Brier tidak berubah jika hanya threshold diganti.

Confusion matrix & kesalahan prediksi


Test: 1.033 tidak churn dan 374 churn



- TP 275: churn berhasil terdeteksi.
- FN 99: churn terlewat.
- FP 243: pelanggan tidak churn ditandai churn.
- TN 790: tidak churn diprediksi benar.
- Precision 53,09%; recall 73,53%. Biaya retensi nyata belum diukur.

ROC & kualitas probabilitas


Kurva dihitung dari model tersimpan pada holdout test



AUC aplikasi 0,8324. Brier turun 0,1741 $\rightarrow$ 0,1414 setelah kalibrasi. Reliability curve memperlihatkan kedekatan prediksi dan frekuensi aktual; bukan jaminan tiap pelanggan.

Interpretasi fitur

Koefisien model inti sebelum kalibrasi



- Tenure negatif: hubungan bersyarat dengan log-odds churn.
- Kontrak bulanan dan fiber punya bobot positif pada model inti.
- Koefisien MonthlyCharges negatif tidak otomatis salah.
- Fitur saling berhubungan; bobot bukan bukti kausal atau peringkat universal.

Arsitektur & implementasi aplikasi

Python • scikit-learn • pandas • joblib • Streamlit

INPUT

Form 18 fitur

CSV UTF-8

Template unduhan

VALIDASI

Kolom & kategori

Angka & rentang

Konsistensi layanan

MODEL

Pipeline preprocess

Sigmoid calibrated

Probabilitas churn

OUTPUT

Threshold 0,32

CHURN/TETAP

Risiko + CSV hasil

Artefak dan metadata diperiksa SHA-256. Hasil lama disembunyikan saat input berubah. CSV invalid ditolak dengan pesan dan nomor baris; tidak dibuang diam-diam.

Demo aplikasi — jalankan langsung

Buka URL live; tunjukkan interaksi, bukan hanya screenshot

- 1. Buka aplikasi: KPI dan tab single, batch, dashboard, serta EDA.
- 2. Isi profil pelanggan; klik Prediksi Sekarang dan jelaskan probabilitas/threshold.
- 3. Download template → upload CSV → tampilkan ringkasan → download hasil.
- 4. Tunjukkan validasi: CSV tanpa tenure atau kategori Contract yang salah.
- 5. Buka dashboard: perbandingan model inti dan evaluasi model aplikasi.

<https://machine-learning-project-u8yovshrqrc5tm5s2y2qto.streamlit.app/>

Kesimpulan

Model terukur, aplikasi berjalan, hasil bisa direproduksi

- LR dipilih berdasarkan CV-F1 training tertinggi (0,6304).
- Konfigurasi aplikasi: sigmoid calibration + threshold 0,32 train-only.
- Test aplikasi: accuracy 75,69%; precision 53,09%; recall 73,53%; F1 0,6166.
- 275 dari 374 churn terdeteksi; 99 terlewat dan 243 false alarm.
- Nilai tambah: probabilitas konsisten, validasi input, batch CSV, dan dashboard evaluasi.

Keterbatasan & pengembangan

Kesimpulan disesuaikan dengan bukti yang tersedia

Keterbatasan	Pengembangan
Dataset historis tunggal; pelanggan tenure 0 dieksklusi	Validasi eksternal/temporal dan uji cohort pelanggan baru
Profil identik lintas split; fitur TotalCharges dibuang tanpa ablation	Group-aware split; ablation fitur; laporkan perubahan performa
RF overfit; FP/FN masih cukup besar	Regularisasi/tuning; alternatif boosting; threshold berbasis biaya nyata
Retensi berbasis aturan; belum diuji efektivitasnya	SHAP dan eksperimen tindakan retensi; monitoring drift

Pembagian tugas

Diisi oleh anggota sesuai pengerjaan aktual — tanpa asumsi peran

Anggota	NIM	Tugas aktual
Muhamad Akhdan Ramadhan	J0404241102	[Isi sendiri]
Thevan Erlangga	J0404241073	[Isi sendiri]
Fachri Abyasa Tarid	J0404241136	[Isi sendiri]

Seluruh anggota wajib memahami konsep, dataset, preprocessing, algoritma, evaluasi, dan aplikasi.

Referensi jurnal

DOI dan teks lengkap tersedia di docs/STUDI_LITERATUR.md

[1] Sana et al. (2022) — PLOS ONE

10.1371/journal.pone.0278095

[2] Y., Ly & Son (2022) — PLOS ONE

10.1371/journal.pone.0267935

[3] Bilal et al. (2022) — PeerJ Computer Science

10.7717/peerj-cs.854

[4] Zhou et al. (2023) — PLOS ONE

10.1371/journal.pone.0292466

[5] Khattak et al. (2023) — Scientific Reports

10.1038/s41598-023-44396-w

Source code & berkas pengumpulan

Format folder: ML2026_B2_Kelompok12_PrediksiCustomerChurn

- PPT: docs/ML2026_B2_Kelompok12_PrediksiCustomerChurn.pptx
- Laporan EDA: folder docs • notebook: projekk.ipynb
- Lima jurnal & tabel: docs/STUDI_LITERATUR.md • docs/jurnal/
- Video demo: maksimal 7 menit, aplikasi dijalankan langsung.
- Pembagian tugas: isi pada slide 27; video asli direkam anggota.

Repository: <https://github.com/makhdanramadhan-ui/Machine-Learning-Project>

<https://machine-learning-project-u8yovshrqrc5tm5s2y2qto.streamlit.app/>